

# Eksploracja Danych Tekstowych

## YouTube Movie Sentiment Analysis

Analiza sentymentu komentarzy YouTube

**Projekt wykonali:** D/XXXXXX Marcin Królczyk, D/YYYYYY Łukasz Cichoń

**Grupa laboratoryjna:** DS1

**Rok studiów:** II

**Semestr:** III

**Specjalność:** Data Science

**Data wykonania:** 03.01.2026

Studia Magisterskie  
2026, PK, WIiM

# Spis treści

<b>1 Wstęp</b>	<b>2</b>
<b>2 Opis projektu</b>	<b>2</b>
2.1 Funkcjonalności aplikacji . . . . .	2
2.1.1 Wsparcie wielojęzyczne . . . . .	2
2.1.2 Analiza sentymentu wspomagana AI . . . . .	2
2.1.3 Wizualizacje graficzne . . . . .	3
2.1.4 Eksploracja komentarzy . . . . .	3
2.1.5 Zaawansowana analityka tekstowa . . . . .	3
2.2 Wymagania systemowe . . . . .	3
2.3 Instrukcja uruchomienia – metoda ręczna . . . . .	3
2.3.1 Krok 1: Klonowanie repozytorium . . . . .	3
2.3.2 Krok 2: Utworzenie i aktywacja wirtualnego środowiska . . . . .	4
2.3.3 Krok 3: Instalacja zależności . . . . .	4
2.3.4 Krok 4: Pobranie modeli językowych spaCy . . . . .	4
2.3.5 Krok 5: Uruchomienie aplikacji . . . . .	4
2.4 Instrukcja uruchomienia z użyciem narzędzia Docker . . . . .	4
2.4.1 Tryb deweloperski (z hot reload) . . . . .	4
2.4.2 Tryb produkcyjny . . . . .	4
2.4.3 Użycie Makefile (zalecane) . . . . .	4
2.4.4 Zmienne środowiskowe . . . . .	5
2.4.5 Architektura Docker . . . . .	5
2.5 Konfiguracja klucza API YouTube . . . . .	5
2.6 Struktura projektu . . . . .	5
<b>3 Technologie</b>	<b>6</b>
3.1 Główne technologie . . . . .	6
3.2 Przetwarzanie języka naturalnego (NLP) . . . . .	6
3.3 Analityka tekstu . . . . .	6
3.4 Wizualizacja danych . . . . .	7
3.5 Integracje zewnętrzne . . . . .	7
3.6 Struktura danych i narzędzia . . . . .	7
<b>4 Przegląd interfejsu użytkownika</b>	<b>7</b>
4.1 Ekran startowy . . . . .	8
4.2 Wyniki analizy – przegląd sentymentu . . . . .	8
<b>5 Wnioski i podsumowanie</b>	<b>11</b>
5.1 Osiągnięte cele . . . . .	11
5.2 Napotkane wyzwania . . . . .	12
5.3 Możliwości rozwoju . . . . .	12
5.4 Podsumowanie . . . . .	12

## 1 Wstęp

Niniejsze sprawozdanie przedstawia projekt realizowany w ramach przedmiotu **Eksploracja Danych Tekstowych** na studiach magisterskich kierunku Data Science. Projekt dotyczy analizy sentymentu komentarzy pod filmami na platformie YouTube, ze szczególnym uwzględnieniem wsparcia wielojęzycznego dla języków polskiego i angielskiego.

Głównym celem projektu było stworzenie aplikacji webowej umożliwiającej:

- Pobieranie komentarzy z dowolnego filmu YouTube za pomocą oficjalnego API
- Automatyczne wykrywanie języka komentarzy (polski/angielski)
- Przeprowadzanie analizy sentymentu z wykorzystaniem modeli transformer
- Wizualizację wyników w postaci interaktywnych wykresów i chmur słów
- Eksplorację zaawansowanych metryk tekstowych (TF-IDF, n-gramy, modelowanie tematów LDA)

Projekt łączy techniki przetwarzania języka naturalnego (NLP) z nowoczesnym interfejsem webowym, demonstrując praktyczne zastosowanie metod eksploracji danych tekstowych w kontekście analizy mediów społecznościowych.

## 2 Opis projektu

### 2.1 Funkcjonalności aplikacji

Aplikacja oferuje szeroki zakres funkcjonalności związanych z analizą danych tekstowych:

#### 2.1.1 Wsparcie wielojęzyczne

- **Automatyczna detekcja języka** – system automatycznie rozpoznaje czy komentarz jest w języku polskim czy angielskim
- **Dedykowane przetwarzanie** – dla każdego języka stosowane są odpowiednie modele spaCy do tokenizacji i lematyzacji
- **Wielojęzyczna analiza sentymentu** – wykorzystanie modelu BERT przeszkolonego na danych wielojęzycznych

#### 2.1.2 Analiza sentymentu wspomagana AI

- Wykorzystanie modelu `nlptown/bert-base-multilingual-uncased-sentiment` z biblioteki HuggingFace Transformers
- Klasyfikacja sentymentu na kategorie: pozytywny, neutralny, negatywny
- Obliczanie współczynnika pewności (confidence score) dla każdej klasyfikacji
- Agregacja statystyk sentymentu dla całego zbioru komentarzy

### 2.1.3 Wizualizacje graficzne

- Interaktywne wykresy Plotly (histogram sentymentu, wykres kołowy rozkładu, scatter plot)
- Chmury słów dla różnych kategorii sentymentu
- Porównawcze chmury słów dla języków polskiego i angielskiego (jeżeli pod danym filmem znajduje się wystarczająca ilość komentarzy w języku polskim oraz angielskim)
- Wykresy słupkowe dla tematów LDA i najpopularniejszych emoji

### 2.1.4 Eksploracja komentarzy

- Filtrowanie po sentymencie i języku
- Sortowanie po wyniku sentymentu, liczbie polubień lub długości
- Eksport wyników do formatu CSV

### 2.1.5 Zaawansowana analityka tekstowa

- **Słowa kluczowe** – ekstrakcja z wykorzystaniem TF-IDF
- **N-gramy** – analiza bigramów i trigramów
- **Modelowanie tematów** – LDA (Latent Dirichlet Allocation) z biblioteki scikit-learn
- **Analiza emoji** – statystyki użycia emotikon w komentarzach

## 2.2 Wymagania systemowe

- Python 3.11.XX (testowane z wersją 3.11.9)
- Klucz API YouTube Data API v3 (dostępny bezpłatnie w Google Cloud Console)
- Minimum 4GB RAM (zalecane 8GB ze względu na modele transformer)
- Około 2GB miejsca na dysku (modele językowe)

## 2.3 Instrukcja uruchomienia – metoda ręczna

### 2.3.1 Krok 1: Klonowanie repozytorium

```
1 git clone <repository-url>
2 cd youtube-movie-sentiment-analysis-project
```

### 2.3.2 Krok 2: Utworzenie i aktywacja wirtualnego środowiska

Windows (PowerShell):

```
1 python -m venv .venv  
2 .\venv\Scripts\Activate.ps1
```

Linux/macOS:

```
1 python -m venv .venv  
2 source .venv/bin/activate
```

### 2.3.3 Krok 3: Instalacja zależności

```
1 pip install -r requirements.txt
```

### 2.3.4 Krok 4: Pobranie modeli językowych spaCy

```
1 python -m spacy download en_core_web_md  
2 python -m spacy download pl_core_news_md
```

### 2.3.5 Krok 5: Uruchomienie aplikacji

```
1 streamlit run dashboard/app.py
```

Aplikacja będzie dostępna pod adresem <http://localhost:8501>

## 2.4 Instrukcja uruchomienia z użyciem narzędzia Docker

Projekt zawiera kompletną konfigurację Docker z multi-stage build, co umożliwia szybkie wdrożenie bez konieczności ręcznej instalacji zależności.

### 2.4.1 Tryb deweloperski (z hot reload)

```
1 docker compose -f docker-compose.yml -f docker-compose.dev.yml up --  
  build
```

### 2.4.2 Tryb produkcyjny

```
1 docker compose -f docker-compose.yml -f docker-compose.prod.yml up -d --  
  build
```

### 2.4.3 Użycie Makefile (zalecane)

Projekt zawiera plik Makefile z wygodnymi skrótami:

```
1 make dev      # Uruchomienie w trybie deweloperskim  
2 make prod    # Uruchomienie w trybie produkcyjnym  
3 make stop     # Zatrzymanie kontenerów  
4 make logs    # Podgląd logów  
5 make shell    # Otwarcie powłoki w kontenerze  
6 make clean    # Czyszczenie zasobów Docker
```

#### 2.4.4 Zmienne środowiskowe

Zmienna	Opis	Wartość domyślna
APP_PORT	Port aplikacji	8501
YOUTUBE_API_KEY	Klucz API YouTube	–
ENV	Środowisko (development/production)	development

Tabela 1: Zmienne środowiskowe aplikacji

#### 2.4.5 Architektura Docker

- **Multi-stage build** – optymalizacja rozmiaru obrazu ( 2GB z modelami)
- **Pre-downloaded models** – modele spaCy i NLTK zawarte w obrazie
- **Health checks** – wbudowany endpoint do monitoringu
- **Non-root user** – uruchomienie jako użytkownik bez uprawnień root
- **Volume caching** – cache modeli HuggingFace między restartami

### 2.5 Konfiguracja klucza API YouTube

1. Przejdź do [Google Cloud Console](#)
2. Utwórz nowy projekt
3. Włącz usługę “YouTube Data API v3”
4. Utwórz credentials → API Key
5. Wprowadź klucz w pasku bocznym aplikacji

### 2.6 Struktura projektu

```

1 youtube-movie-sentiment-analysis-project/
2 |-- src/                               # Moduły podstawowe
3 |   |-- config.py                      # Konfiguracja i stałe (zmienne const)
4 |   |-- youtube_client.py              # Integracja z YouTube API
5 |   |-- language_detector.py           # Detekcja języka
6 |   |-- text_preprocessor.py            # Czyszczenie i tokenizacja tekstu
7 |   |-- sentiment_analyzer.py          # Analiza sentymentu (transformers)
8 |   '-- text_analytics.py              # Chmury slow, tematy, n-gramy
9 |-- dashboard/                         # Aplikacja Streamlit
10 |   |-- app.py                         # Główna aplikacja
11 |   |-- components/                   # Komponenty UI
12 |       |-- sidebar.py                # Panel boczny
13 |       |-- metrics.py                # Metryki
14 |       |-- charts.py                 # Wizualizacje Plotly
15 |       '-- wordcloud.py              # Wyświetlanie wykresów typu wordcloud
16 |   '-- styles/                       # Niestandardowe style CSS
17 |       '-- custom.css
18 |-- scripts/                          # Skrypty Docker
19 |   |-- entrypoint.sh                # Uruchomienie kontenera
20 |   '-- healthcheck.py               # Endpoint health check
21 |-- Dockerfile                        # Obraz Dockerowy
22 |-- docker-compose.yml                # Bazowa konfiguracja dla Docker Compose
23 |-- docker-compose.dev.yml            # Override bazowej konfiguracji dla środowiska DEV

```

```

24 |-- docker-compose.prod.yml      # Override bazowej konfiguracji dla środowiska PROD
25 |-- Makefile                   # Skróty polecen
26 |-- requirements.txt           # Moduły/biblioteki Python
27 '-- README.md                 # Dokumentacja projektu

```

## 3 Technologie

Projekt wykorzystuje szereg współczesnych technologii i bibliotek do przetwarzania języka naturalnego oraz tworzenia interaktywnych wizualizacji.

### 3.1 Główne technologie

Komponent	Technologia
Język programowania	Python 3.11
Framework webowy	Streamlit 1.28+
Infrastruktura	Docker, Docker Compose

Tabela 2: Podstawowe technologie

### 3.2 Przetwarzanie języka naturalnego (NLP)

Biblioteka	Zastosowanie
HuggingFace Transformers	Analiza sentymentu z wykorzystaniem wielojęzycznego modelu BERT ( <code>nlptown/bert-base-multilingual-uncased-sentiment</code> )
PyTorch	Backend dla modeli transformer
spaCy	Tokenizacja, lematyzacja, modele językowe ( <code>en_core_web_md</code> , <code>pl_core_news_md</code> )
NLTK	Tokenizacja, stopwords, stemming
langdetect	Automatyczna detekcja języka komentarzy
stopwordsiso	Profesjonalne listy stop-words zgodne z ISO

Tabela 3: Biblioteki NLP

### 3.3 Analityka tekstowa

Biblioteka	Zastosowanie
scikit-learn	TF-IDF, modelowanie tematów LDA, przetwarzanie wektorowe
gensim	Dodatkowe narzędzia do topic modeling
wordcloud	Generowanie chmur słów

Tabela 4: Biblioteki analityki tekstowej

### 3.4 Wizualizacja danych

Biblioteka	Zastosowanie
Plotly	Interaktywne wykresy (histogram, kołowy, scatter, słupkowy)
Matplotlib	Rendering chmur słów

Tabela 5: Biblioteki wizualizacji

### 3.5 Integracje zewnętrzne

Usługa	Zastosowanie
Google YouTube Data API v3	Pobieranie komentarzy z filmów YouTube

Tabela 6: Integracje API

### 3.6 Struktura danych i narzędzia


Biblioteka	Zastosowanie
pandas	Manipulacja i analiza danych tabelarycznych
numpy	Operacje numeryczne na tablicach
python-dotenv	Zarządzanie zmiennymi środowiskowymi

Tabela 7: Biblioteki pomocnicze

## 4 Przegląd interfejsu użytkownika


W tej sekcji przedstawiono zrzuty ekranu prezentujące główne widoki i funkcjonalności aplikacji.

## 4.1 Ekran startowy




Rysunek 1: Ekran startowy aplikacji z panelem bocznym do wprowadzania danych

## 4.2 Wyniki analizy – przegląd sentymentu




Rysunek 2: Przegląd sentymentu fragment nr. 1




Rysunek 3: Przegląd sentymentu fragmentu nr. 2




Rysunek 4: Przeglad sentymentu fragment nr. 3



Rysunek 5: Przegląd sentymentu fragment nr. 4




Rysunek 6: Przegląd sentymentu fragment nr. 5



Rysunek 7: Przegląd sentymentu fragment nr. 6



Rysunek 8: Przegląd sentymentu fragment nr. 7



Rysunek 9: Przegląd sentymentu fragment nr. 8

## 5 Wnioski i podsumowanie

### 5.1 Osiągnięte cele

Projekt został zrealizowany zgodnie z założeniami i obejmuje:

- Kompletną aplikację webową** – interaktywny dashboard Streamlit umożliwiający analizę komentarzy YouTube
- Wielojęzyczne przetwarzanie NLP** – automatyczna detekcja języka i dedykowane pipeline'y (wsparcie dla języków: polskiego i angielskiego)
- Zaawansowaną analizę sentymentu** – wykorzystanie state-of-the-art modelu BERT przeszkolonego na danych wielojęzycznych
- Bogate wizualizacje** – interaktywne wykresy Plotly, chmury słów z podziałem na kategorie sentymentu
- Analitykę tekstową** – ekstrakcja słów kluczowych TF-IDF, analiza n-gramów, modelowanie tematów LDA
- Konteneryzację aplikacji** – kompletna konfiguracja Docker z multi-stage build oraz health checks, umożliwiająca łatwy deploy aplikacji w przyszłości

## 5.2 Napotkane wyzwania

Podczas realizacji projektu napotkano następujące wyzwania techniczne:

- **Limity API YouTube** – dzienny limit 10,000 jednostek (dla darmowej wersji)
- **Rozmiar modeli transformer** – pierwsze uruchomienie wymaga pobrania 500MB modeli
- **Wydajność** – przetwarzanie dużej liczby komentarzy z wykorzystaniem modeli BERT wymaga optymalizacji batch processing
- **Wielojęzyczność** – konieczność obsługi specyfiki języka polskiego (odmiany, stopwords)

## 5.3 Możliwości rozwoju

Projekt może być rozbudowany o następujące funkcjonalności:

- Wsparcie dla dodatkowych języków (niemiecki, hiszpański, etc.)
- Analiza sentymetu w czasie – śledzenie zmian nastrojów komentarzy w momencie publikacji
- Porównywanie wielu filmów jednocześnie
- Automatyczne generowanie raportów PDF
- Integracja z dodatkowymi platformami (Twitter/X, Reddit)
- Fine-tuning modelu BERT na danych specyficznych dla recenzji filmowych

## 5.4 Podsumowanie

Aplikacja demonstruje praktyczne zastosowanie technik eksploracji danych tekstowych w kontekście analizy mediów społecznościowych. Połączenie nowoczesnych modeli NLP (transformers) z interaktywnym interfejsem webowym (Streamlit) pozwala na efektywną i intuicyjną analizę dużych zbiorów komentarzy tekstowych. Wielojęzyczne wsparcie dla języka polskiego i angielskiego czyni narzędzie użytecznym zarówno dla polskich, jak i zagranicznych treści na platformie YouTube.